

# **Aprendizagem Profunda**

Grupo 11

João Coelho - PG55954

João Faria - PG55953

Jorge Teixeira - PG55965

Rafael Alves - PG55999

# Construção do Dataset

- **Primeira fase:** Utilização de *dataset* colocado no enunciado, de tópico geral, utilizando partes dos mesmos.
- **Segunda e terceira fase:** Criação de dataset próprio, usando API da Wikipédia e LLMs (*Deepseek* localmente e API do *Gemini*), respeitando o tema do dataset de validação da equipa docente.

# Modelos em *Numpy* - Fase 1

- Implementação manual com recurso a Numpy de modelos de *Logistic Regression*, *Deep Neural Network* e *Recurrent Neural Network*.
- **Pré processamento:**
  - Dataset tratado substituindo maiúsculas, pontos e as chamadas "stopwords" (*nltk*)
  - Vetorizado usando o **TfidfVectorizer** (biblioteca *sklearn*), mantendo apenas as 1000 palavras mais frequentes
  - Treinado um modelo Word2Vec (biblioteca *gensim*) que aprende representações vetoriais com um vetor de tamanho 300, janela de 5 palavras e mínimo de 2 ocorrências por palavra.
  - Matriz de *embedding* onde se associa uma palavra a um vetor, criando sequências numéricas a partir dos textos, substituindo as palavras por índices na matriz de embeddings.
  - Aplicado ao dataset de teste e resultados armazenados

# Modelos em *Numpy* - Fase 1

- **Logistic Regression:** Taxa de aprendizagem de 0.01 e configurado para treinar por 300 epochs
- **Deep Neural Network:**
  - Primeira camada do tamanho do input
  - Camada oculta de 32 neurónios, regularização L2 (peso de 0.05), **normalização** das ativações e função de ativação **ReLU** e **dropout** de 50%
  - Segunda camada oculta igual à primeira, mas com 16 neurônios
  - Camada de saída com um neurônio com função de ativação sigmóide
  - Loss Function de FocalLoss, focando-se em accuracy, learning rate de 0,0001 e momentum de 0,9. Batch size de 128 com 100 epochs e early stopping de 5 epochs. Scheduler de learning rate com decay de 0,2 e Mixup Data Augmentation com mixup\_alpha=0.2

# Modelos em *Numpy* - Fase 1

- ***Recurrent Neural Network:***

- Entrada com sequências processadas, coluna objetivo e matriz de embeddings
- Camada recorrente com 64 unidades e dropout de 50%
- Otimização feita com o algoritmo Adam, taxa de aprendizagem adaptativa (lr=0.0005)
- Treino com 15 epochs e tamanho de batch de 16

# Modelos em *Tensorflow* - Fase 2

- Implementação com recurso a *Tensorflow* de modelos de *Deep Neural Network*, *Recurrent Neural Network* (LSTM e GRU), *Transformer* e *Ensemble*.
- **Pré processamento:**
  - Utilizado dataset gerado, uso de *Tokenizer* e *pad\_sequences* (*TensorFlow*).
  - Extração de features (comprimento médio das frases, diversidade lexical, frequência de pontuação e de pronomes de primeira pessoa)
  - Modelos *Word2Vec*, armazenados os embeddings como matriz customizada
  - Metadados guardados

# Modelos em *Tensorflow* - Fase 2

- **Recursive Neural Networks [LSTM]:**
  - Camada de embedding
  - Duas camadas bidirecionais (128  $\rightarrow$  64 unidades)
  - Dropout e Recurrent Dropout  $\rightarrow$  30%
  - Camada densa de 32 neurônios com ativação ReLU e regularização L2 (0,001) e camada de saída sigmóide.
- **Recursive Neural Networks [GRU]:**
  - Estrutura semelhante a LSTM
  - Camada *Conv1D*  $\rightarrow$  128 filtros (antes das camadas bidirecionais)
- Ambas utilizam **Adam** com learning rate de 0,001 e função de perda **binary\_crossentropy**

# Modelos em *Tensorflow* - Fase 2

- **Transformer:**

- Como entrada a camada de *Embedding*
- Múltiplos blocos de self-attention com cabeças de atenção de 64 (8, no total)
- 4 camadas de *feed-forward* de 256 unidades
- Extração de características com *GlobalAveragePooling1D*
- Camadas densas com ativação **ReLU** e regularização L2
- Mesma configuração de outros modelos, mas com *fine tuning* com *learning rate* de 0,0005



# Modelos em *Tensorflow* - Fase 2

- **Deep Neural Network:**

- Trabalha sobre features tabulares extraídas dos textos
- Camadas densas de  $128 \rightarrow 64 \rightarrow 32$  neurônios com ativação *Leaky ReLU*, *Batch Normalization*, *Dropout* de 50% e *L2 regularization* (0,001)
- Termina com uma camada sigmóide para saída probabilística
- Compilado com **Adam** (lr=0,001) e *binary crossentropy*

- **Ensemble:**

- Combina modelos anteriormente abordados
- Recebe como entrada as saídas de cada um dos modelos individuais e processa por meio de camadas densas com ativação ReLU, regularização L2 e dropout

## Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)

- Passámos a utilizar **Jupyter Notebooks**, com um notebook dedicado para cada modelo, onde todo o pré-processamento e treino são realizados diretamente.
- Simplificamos o **pré-processamento**, abandonamos o **Word2Vec** e passamos a utilizar **embedding treinável** inicializado com **GlorotUniform**.
- Descobrimos o **Keras Tuner**, o que nos permitiu realizar um ajuste muito mais eficiente dos hiperparâmetros.
- Os resultados obtidos foram significativamente melhores, como veremos a seguir.

# Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)

- **Deep Neural Network:**
  - **Pré-processamento:** Normalização, remoção de maiúsculas, URLs e emails;
  - **Arquitetura:** 4 camadas ocultas (216 → 88 → 216 → 120 neurônios);
  - **Ativação:** ReLU + normalização;
  - **Dropout:** 10% → 10% → 40% → 30%;
  - **Saída:** 1 neurônio (sigmóide);
  - **Treino:** Adam ( $lr \approx 0,00019$ ), binary crossentropy, early stopping (2 epochs);
  - **Modelo final:** Early Stopping + ReduceLROnPlateau.

# Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)

- **Recurrent Neural Network - Melhor LSTM:**
  - **Pré-processamento:** Tokenizer + tratamento de dados;
  - **Camadas:**
    - **Embedding** (dim=64) → **Spatial Dropout** (20%);
    - **LSTM 1:** 40 unidades, dropout 50%, recurrent dropout 20%;
    - **LSTM 2:** 64 unidades, dropout 20%, recurrent dropout 40%;
    - **Densa:** 1 unidade (sigmóide);
  - **Otimização:** Adam (lr = 0,00038), binary\_crossentropy;
  - **Treino:** Early Stopping (5 epochs), ReduceLROnPlateau (paciente 2 epochs);
  - **Configuração:** 25 epochs máx., batch size 32.


# Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)

- Recurrent Neural Network - Melhor GRU:
  - Camadas:
    - **Embedding** (dim=64, GlorotUniform) → **Spatial Dropout** (30%);
    - **Conv1D** (ReLU);
    - **GRU 1**: 56 unidades, dropout 20%, recurrent dropout 30%;
    - **GRU 2**: 8 unidades, dropout 10%, recurrent dropout 20%;
    - **Densa**: 1 unidade (sigmóide);
  - **Otimização**: Adam (lr = 0,006), binary\_crossentropy;
  - **Treino**: Early Stopping (5 epochs), ReduceLROnPlateau (paciente 2 epochs);
  - **Configuração**: 25 epochs máx., batch size 32.

# Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)

- **Ensemble:**
  - Junta os modelos anteriores e um transformer
  - Primeira camada densa de 48 neurônios com dropout de 50%
  - Segunda camada densa de 32 neurônios e dropout de 30%
  - Taxa de aprendizagem de aproximadamente 0,0018 e otimizador Adam
  - Tuner configurado com 2 epochs iniciais e 2 brackets

# Modelos em *Tensorflow* - Fase 3 (em desenvolvimento)



# **Aprendizagem Profunda**

Grupo 11

João Coelho - PG55954

João Faria - PG55953

Jorge Teixeira - PG55965

Rafael Alves PG-55999